



MACHINE LEARNING CON PYTHON

TEMA 1. Introducción al Machine Learning



Sobre el Formador

/ Iván Palomares Carrascosa

Ingeniero Superior (2009) y Doctor (2014) en Informática
Master en Sistemas Inteligentes (2011)

Ex-profesor de universidad e investigador (2012-2022)

- Machine Learning, Análisis y Ciencia de Datos
- Inteligencia Artificial Aplicada

Actualmente *freelance*:

- Formador a medida para empresas y organizaciones.
- Colaborador docente y consultor con escuelas de negocio.
- Escritor y redactor en tech blogs internacionales.
- Formador IT homologado por la EOI (Escuela de Organización Industrial)



Contenidos Tema 1

- / 1. Introducción al Machine Learning
- / 2. Tipos de aprendizaje y ciclo de vida

ENLACE A GITHUB CON LOS MATERIALES:


<https://github.com/IconoTC/Machine-Learning-con-PYTHON-AF-75648-Grupo-102788>

REPOSITORIO DE DATASETS PARA EL CURSO: <https://github.com/gakudo-ai/open-datasets>

INTELIGENCIA ARTIFICIAL


Ciencia e ingeniería centrada en construir máquinas que aprenden a emular ciertos aspectos de la inteligencia humana (o animal) para resolver un problema determinado

- Aprendizaje (a partir de datos)
- Razonamiento: lógico, matemático, visual, ...
- Toma de decisiones
- Comunicación (con humanos, con otros sistemas, ...)




INTELIGENCIA ARTIFICIAL

Ciencia e ingeniería centrada en construir máquinas que aprenden a emular ciertos aspectos de la inteligencia humana (o animal) para resolver un problema determinado



INTELIGENCIA ARTIFICIAL

Ciencia e ingeniería centrada en construir máquinas que aprenden a emular ciertos aspectos de la inteligencia humana (o animal) para resolver un problema determinado



INTELIGENCIA ARTIFICIAL

Inteligencia Artificial

VS

Inteligencia Artificial
General (AGI)

¿Qué es capaz de hacer?	Aplicaciones
Recolecta, interpreta, aprende, y toma decisiones a partir de datos. Habilidad para resolver una tarea específica .	Reconocimiento facial Asistentes de voz Recomendaciones personalizadas Robots de manufacturación Etc.
Iguala o excede la inteligencia humana Habilidad para resolver un conjunto variado de tareas inteligentemente	Aplicaciones "a medio camino" de ser AGI: Vehículos autónomos Aplicaciones multimodales de IA generativa: ChatGPT, Copilot, Gemini Etc.

FUNCIONES QUE LA IA PUEDE DESEMPEÑAR

Predicciones e inferencia: función clave de los sistemas de Machine Learning (aprendizaje automático). Aprender a realizar predicciones u otros tipos de inferencia (clasificaciones, estimaciones, pronóstico, ...) en base a datos




FUNCIONES QUE LA IA PUEDE DESEMPEÑAR

Predicciones e inferencia: tareas de aprendizaje (ML) supervisado

Requisito: disponer de un conjunto de datos de ejemplo cuyo valor de salida ya es conocido □ datos de entrenamiento.

Regresión

Predecir variable continua en función de otras variables relacionadas



Pronóstico de series temporales

Predecir valor futuro continuo a partir de valores pasados con orden temporal



Clasificación

Asignar clase o categoría de nuevos datos o ejemplos a partir de variables




1. INTRODUCCIÓN AL MACHINE LEARNING

FUNCIONES QUE LA IA PUEDE DESEMPEÑAR

Reconocimiento de patrones: identificar características o patrones en los datos, para ayudar a tomar decisiones → aprendizaje (ML) no supervisado

- Clustering (agrupamiento)
- Detección de anomalías
- Generación de nuevos datos (IA generativa)



FUNCIONES QUE LA IA PUEDE DESEMPEÑAR

Optimización: encontrar la mejor solución posible a un problema a un coste mínimo, p.ej. diseñar una campaña de marketing que maximice ingresos

Automatización: aplicar una serie de reglas o pasos que requieren habilidades inteligentes, para llevar a cabo tareas arduas o repetitivas



IA

≠

Automatización

IA










Ayuda a
mejorar la

Automatización

FUNCIONES QUE LA IA PUEDE DESEMPEÑAR

Personalización: uso combinado de otras habilidades de la IA (predicciones, inferencia, descubrir patrones, ...) para tomar o sugerir decisiones adaptadas a las necesidades/intereses del usuario o cliente

Basado en tus tendencias de compra



Introducción a Scikit-Learn, TensorFlow y Keras

Librerías y APIs Python para ML



Scikit-learn

- ML tradicional accesible y eficiente
- Algoritmos y modelos de clasificación, regresión, clustering, etc.
- Preprocesamiento de datos, reducción de dimensionalidad y evaluación de modelos



Keras

- API de alto nivel integrada en Tensorflow para *deep learning*
- Simplifica construcción de arquitecturas de redes neuronales
- Permite un prototipado más fluido



TensorFlow

- Construcción de modelos a gran escala
- Foco en redes neuronales profundas (deep learning) y aprendizaje distribuido
- Flexibilidad y soporte multiplataforma


Introducción a Scikit-Learn, TensorFlow y Keras

Librerías y APIs Python para ML




	Scikit-Learn	TensorFlow	Keras
Enfoque	Machine Learning clásico	Aprendizaje profundo y escalable	API amigable para redes neuronales
Facilidad de uso	Intuitivo y sencillo	Complejo pero flexible	Muy fácil y accesible
Escalabilidad	Datos medianos	Alta (GPU/TPU)	Alta (hereda TensorFlow)
Aplicación	Modelos clásicos (SVM, árboles)	Redes profundas avanzadas	Prototipos rápidos de deep learning

MACHINE LEARNING (APRENDIZAJE AUTOMÁTICO)



Áreas del Machine Learning

MACHINE LEARNING (APRENDIZAJE AUTOMÁTICO)



Áreas del Machine Learning

CONCEPTOS BÁSICOS DE MACHINE LEARNING

Aprendizaje Supervisado: tenemos ejemplos de datos *etiquetados* (con clase o variable a predecir conocida) → **datos de entrenamiento**

Cada observación o instancia consta de:

- Uno o varios atributos de entrada/predictores (*features*)
- La salida o variable a predecir: etiqueta (*label*)

Inputs = features						Output (class/label)
island	bill length (mm)	bill depth (mm)	flipper length (mm)	body mass (g)	sex	species
Torgersen	39.1	18.7	181	3750	male	Adelie
Torgersen	39.5	17.4	186	3800	female	Adelie
Biscoe	46.3	15.8	215	5050	male	Gentoo
Biscoe	42.9	13.1	215	5000	female	Gentoo
Torgersen	36.7	19.3	193	3450	female	Adelie
Torgersen	39.3	20.6	190	3650	male	Adelie
Torgersen	38.9	17.8	181	3625	female	Adelie

CONCEPTOS BÁSICOS DE MACHINE LEARNING


Mediante **datos de entrenamiento** etiquetados, se **entrena** o construye un **modelo de ML** que aprenderá a realizar una tarea predictiva sobre futuros datos no etiquetados = variable de salida desconocida.

Inputs = features

Output (class/label)

island	bill length (mm)	bill depth (mm)	flipper length (mm)	body mass (g)	sex	species
Torgersen	39.1	18.7	181	3750	male	Adelie
Torgersen	39.5	17.4	186	3800	female	Adelie
Biscoe	46.3	15.8	215	5050	male	Gentoo
Biscoe	42.9	13.1	215	5000	female	Gentoo
Torgersen	36.7	19.3	193	3450	female	Adelie
Torgersen	39.3	20.6	190	3650	male	Adelie
Torgersen	38.9	17.8	181	3625	female	Adelie

Datos de entrenamiento con etiquetas (training data)




CONCEPTOS BÁSICOS DE MACHINE LEARNING

Aprendizaje Supervisado

Una vez construido el modelo, se utilizar para **realizar inferencia: predicciones sobre datos de prueba** (*test*), evaluar su rendimiento, y posteriormente desplegarlo en entornos donde recibirá datos reales.


Datos de prueba (clase desconocida)




EL PROBLEMA DEL SOBREAJUSTE (OVERFITTING)

Aprender en exceso de los datos de entrenamiento podría no ser precisamente algo bueno


- “Memorizar” en lugar de aprender patrones generalizables a futuros ejemplos de datos no vistos durante el entrenamiento → sobreajuste
- Un buen modelo es el que no solo aprende de los datos de entrenamiento en sí, sino que es capaz de generalizar a futuros datos




Underfitted




Good Fit/Robust




Overfitted



High training error
High test error



Low training error
Low test error




Low training error
High test error


EL PROBLEMA DEL SOBREAJUSTE (OVERFITTING)

¿Cómo combatir el sobreajuste?


- **Simplificar el modelo:** elegir un tipo de modelo con menos parámetros, reducir atributos en el *dataset*, o restringe su capacidad de aprendizaje mediante técnicas de regularización.
- Recolectar más datos de entrenamiento
- Reducir el ruido en los datos de entrenamiento disponibles: errores e inconsistencias, *outliers*.






Underfitted



Good Fit/Robust




Overfitted

High training error
High test errorLow training error
Low test errorLow training error
High test error


Aprendizaje no supervisado

- **A menudo, los datos históricos reales no están etiquetados.**
 - Los algoritmos de aprendizaje no supervisado extraen conocimiento y patrones de estos datos sin etiquetar.

Clustering: encontrar subgrupos con características similares




Detección de anomalías: identificar observaciones "inusuales", por ejemplo, transacciones bancarias sospechosas




Aprendizaje no supervisado

- **A menudo, los datos históricos reales no están etiquetados.**
 - Los algoritmos de aprendizaje no supervisado extraen conocimiento y patrones de estos datos sin etiquetar.

Descubrimiento de reglas de asociación:
encontrar co-ocurrencias frecuentes en datos de carácter transaccional.




Reducción de la dimensionalidad: reducir número de atributos en los datos, manteniendo sus propiedades clave (útil p.ej. en datos de imágenes)



Aprendizaje por Refuerzo

- Algoritmos que aprenden en base a la experiencia
 - Una entidad (agente) con un objetivo, va aprendiendo cómo realizar una tarea compleja en base a tomar decisiones, ejecutar acciones, y evaluar el resultado de las mismas




Aprendizaje por Refuerzo

- **Algoritmos que aprenden en base a la experiencia**
 - Una entidad (agente) con un objetivo, va aprendiendo cómo realizar una tarea compleja en base a tomar decisiones, ejecutar acciones, y evaluar el resultado de las mismas

Nombre	Descripción
Q-Learning	El sistema aprende creando una especie de "tabla de puntuaciones". En ella anota qué nota merece cada acción en cada situación diferente, para elegir siempre la opción con la puntuación más alta.
SARSA	Es muy similar a Q-Learning, pero más realista y precavido. Aprende evaluando el peligro o beneficio de las acciones que realmente va a tomar en el siguiente paso, en lugar de asumir que siempre todo saldrá perfecto.
DQN (Redes Q Profundas)	Se utiliza cuando las situaciones posibles son infinitas (como los píxeles de un videojuego). En lugar de una tabla física, utiliza un "cerebro artificial" que le permite adivinar y recordar qué acciones funcionan mejor en situaciones parecidas.
PPO (Optimización de Política Próxima)	En lugar de poner notas a las acciones individuales, el sistema entrena directamente una "guía de comportamiento". Aprende modificando esta guía de forma muy controlada y con pasos pequeños, evitando hacer cambios bruscos que arruinen lo que ya sabe hacer bien.

CICLO DE VIDA CLÁSICO DEL MACHINE LEARNING




1. Formular el problema

- Definir el(los) objetivo(s) de negocio.
- Identificar las soluciones existentes y su uso.
- Formular el tipo de problema y la tarea de ML.
- Criterios de rendimiento y éxito.
- Roles y recursos necesarios, ...

2. Obtener los datos

- Orígenes de los datos: ¿qué datos y cuántos?
- Dónde almacenarlos: ¿en las instalaciones locales (*on-premises*) o en la nube?
- Consideraciones legales y éticas.
- Separar en datos de entrenamiento y de prueba.
- Automatizar lo máximo posible (ETL, *pipelines* o tuberías de datos).

CICLO DE VIDA CLÁSICO DEL MACHINE LEARNING




3. Explorar y entender los datos

- Crear una copia o muestra para la exploración.
- Estudiar atributos, correlaciones, distribuciones y problemas como el ruido y los valores faltantes...
- Visualizar los datos.
- ¡Lo mejor es tener a un experto del dominio a bordo!

4. Preparar los datos para ML

- Mantener una copia de seguridad de los datos originales (¡los accidentes ocurren!).
- Limpieza de datos: valores atípicos (*outliers*), valores faltantes...
- Selección e ingeniería de características (*Feature selection and feature engineering*).
- ¡En el ML clásico, esta suele ser la fase más laboriosa!

CICLO DE VIDA CLÁSICO DEL MACHINE LEARNING




5. Seleccionar, entrenar y evaluar modelos de ML

- Entrenar varios modelos para la tarea objetivo.
- Basándose en las métricas, ver el rendimiento del modelo.
- Analizar los parámetros aprendidos por el modelo.
- Usar *pipelines* de entrenamiento para automatizar el proceso.

6. Ajustar (*Fine-tuning*) los modelos prometedores

- Identificar los modelos prometedores entrenados en la fase anterior.
- Intentar refinar usando validación cruzada y técnicas de búsqueda para encontrar la mejor configuración del modelo.
- Intentar combinar múltiples modelos en una sola tarea: ensamblaje (*ensemble*).
- Evaluar el/los modelo(s) optimizado(s) en los datos de prueba.

CICLO DE VIDA CLÁSICO DEL MACHINE LEARNING



7. Presentar la solución

- Documentar todo el trabajo realizado a lo largo del proyecto.
- Hacer un discurso de presentación (*pitch*) visualmente atractivo y convincente.
- Justificar por qué la solución logra el/los objetivo(s).

8. Despliegue, monitorización y mantenimiento

- Preparar la solución para el entorno de producción: operacionalización.
- Monitorizar la degradación del modelo, las derivas de datos (*data drifts*), ...
- Reentrenar regularmente el/los modelo(s) con nuevos datos recientes.

MACHINE LEARNING OPERATIONS (MLOps)

La operacionalización y gestión eficiente y confiable de sistemas de IA – predominantemente de machine learning- en entornos organizativos y de industria

